



## Interpretación de datos de FastQC y multiQC


- Evalúa la calidad de los datos de secuenciación masiva previo a ingresarlas al ensamblador

### FastQC

Un archivo por secuencia/muestra



Principalmente para detectar si el final de las lecturas tiene baja calidad, en Illumina la calidad decae hacia el extremo 3' (el final de la secuencia).




## MultiQC

Recopila automáticamente todos los reportes de FastQC y genera un único informe comparativo. Los mismos apartados se desglosan en MultiQC (nuestros archivos lecturas forward y reverse en paired-end).


### Información general

- **Dups:** Cuántas lecturas se repiten exactamente de forma idéntica. Un nivel de duplicación de entre el 20% y 30% es completamente normal
- **GC:** La proporción de bases Guanina (G) y Citosina (C) está alrededor del 39-40%. Esto es característico con los genomas de cloroplasto (plantas), suelen ser ricos en AT y tener un contenido de GC de entre el 35% y 40%.
- **Median len:** Indica la longitud promedio en pares de bases (bp) de tus lecturas. La longitud mediana es alta. Esto sugiere que las lecturas conservaron casi toda su longitud tras el procesamiento.
- **Seqs:** Lecturas por archivo



### Recuento de secuencias


En color azul se muestran las secuencias que aparecen una vez y en gris las que se repiten de forma idéntica 2 o más veces.



### Histogramas de calidad de secuencia

La gráfica se divide horizontalmente en tres colores que indican la confiabilidad de las bases secuenciadas. En el eje de las X se muestran la posición de la base y en el eje de las Y la calidad.


En este caso, se observan las lecturas iniciales de 0 a 100 pb en la zona verde (mayor probabilidad de que la base sea correcta o una probabilidad de error de 1 en 1000) de buena calidad, a partir de la 150 pb la calidad cae, sin embargo debido al tipo de secuenciación es normal que la calidad decaiga conforme aumenta la longitud de la lectura.



## Calidad por secuencia

Muestra la calidad promedio de cada lectura. En el eje de las X el valor de la calidad promedio (Q) y en el eje de las Y la cantidad de lecturas.

La mayor parte de las lecturas tienen una calidad promedio entre Q30 y Q37. La línea amarilla representa las lecturas en reversa (*Reverse*), las cuales muestran una calificación notablemente más baja debido al desgaste normal del equipo durante la secuenciación. La línea verde representa las lecturas hacia adelante (*Forward*).




## Contenido de secuencia por base

Proporción de A, T, G y C en cada posición. Ayuda a detectar sesgos durante la secuenciación.

Tiene un inicio inestable, aunque se asume que desde el inicio las distribuciones de las bases serán aleatorias, la realidad es que las enzimas del ADN no cortan de manera aleatoria

Final: el secuenciador empieza a cometer errores o a perder intensidad de señal, la asignación de bases se vuelve imprecisa y altera las proporciones reales




### Porcentaje de G-C por secuencia

En una librería genómica ideal, la distribución del contenido GC debe verse como una campana simétrica.


Los genomas de los cloroplastos en plantas terrestres son evolutivamente ricos en Adeninas y Timinas (AT), lo que hace que su contenido GC sea característicamente bajo Firma molecular.

Comportamiento que indica que no hay contaminación por bacterias, hongos o hasta adaptadores de secuenciación mal cortados.



### Contenido de N por base


El software del secuenciador asigna una "N", lo que significa "base desconocida", si no determina una base.



### Distribución de la longitud de las secuencias

Mide la longitud (el tamaño en pares de bases, bp) de tus lecturas de ADN y cuenta cuántas lecturas tienen cada tamaño.

Amarillo: El software espera que en datos crudos de Illumina todas las lecturas tengan exactamente la misma longitud



### Niveles de duplicación

Mide qué tan diversa es tu librería de ADN evaluando cuántas veces se repite exactamente una misma secuencia. Se espera que la mayoría de las lecturas estén en el nivel 1 (secuencias únicas).

Al mapear o secuenciar con una cobertura profunda un genoma tan pequeño, por puro azar estadístico vas a secuenciar los mismos fragmentos exactos muchas veces. Además, los cloroplastos contienen regiones altamente repetitivas (IR), que al duplicar de forma natural ciertas porciones del genoma, elevan artificialmente este conteo de duplicados en la gráfica.

